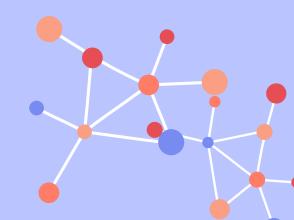


Mineração e Análise de Dados de Bioinformática Estrutural: Análise de Estruturas de Interações Proteína-RNA Modeladas por Métodos Computacionais

João Pedro Braga Ennes





BANCO DE DADOS PROTÍNA-RNA



No último semestre construímos um banco de dados de estruturas de interações proteína-rna, com informações do PDB, obtidas de forma experimental.

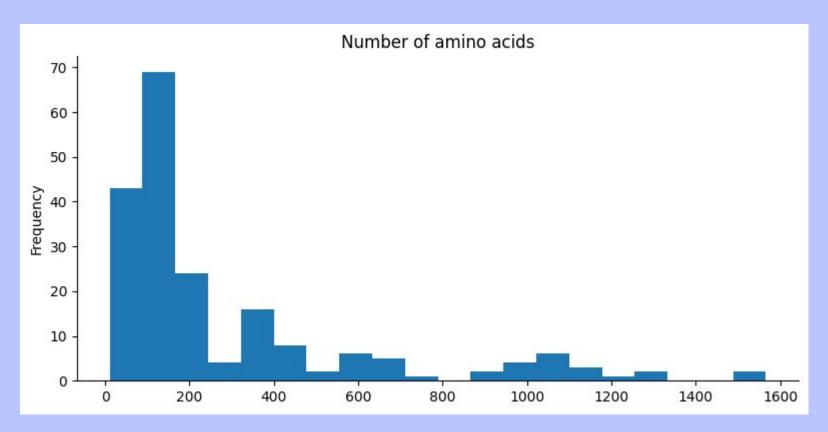
Inicialmente coletamos informações de 309 estruturas e após realizar algumas análises, removemos algumas que não se encaixavam no nosso grupo de interesse e obtivemos ficando no final com 198 estruturas.





HISTOGRAMA AMINOÁCIDOS

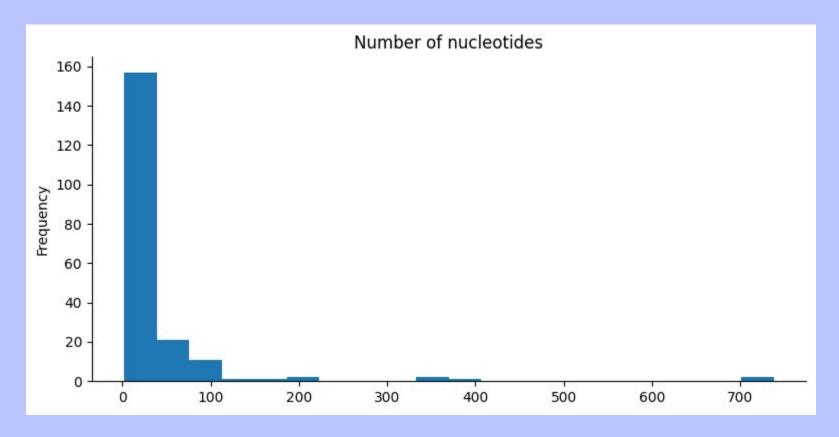






HISTOGRAMA NUCLEOTÍDEOS





BANCO DE DADOS PROTÍNA-RNA



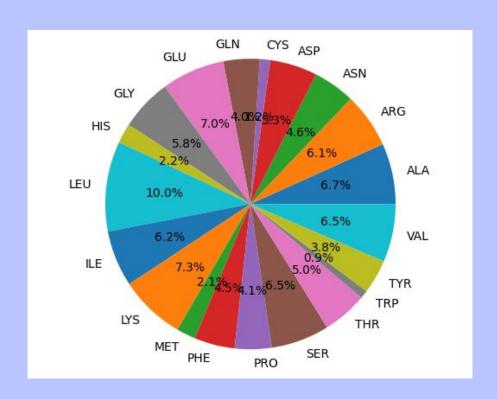
| | Structure | Number of amino acids | Number of nucleotides | | |
|-----|-----------|-----------------------|-----------------------|--|--|
| 0 | 1a4t | 19 | 15 | | |
| 1 | 1biv | 17 | 28 | | |
| 2 | 1aud | 101 | 30 | | |
| 3 | 1exy | 16 | 33 | | |
| 4 | 1etf | 23 | 34 | | |
| | *** | *** | | | |
| 165 | 7zpi | 705 | 55 | | |
| 166 | 8fti | 737 | 97 | | |
| 167 | 8e28 | 690 | 15 | | |
| 168 | 8e2a | 686 | 15 | | |
| 169 | 8acc | 231 | .5 | | |

Ao final de todos os filtros, ficamos com um total de **170** estruturas no nosso banco



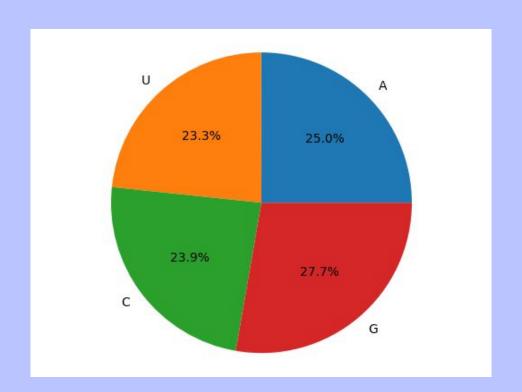
Frequência por Aminoácido

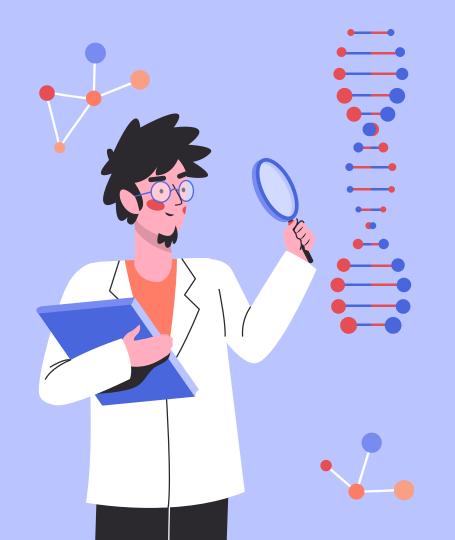


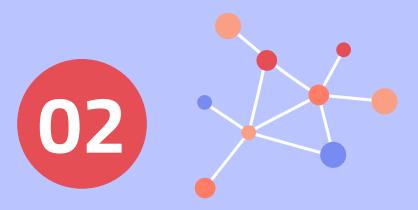


Frequência por Nucleotídeo





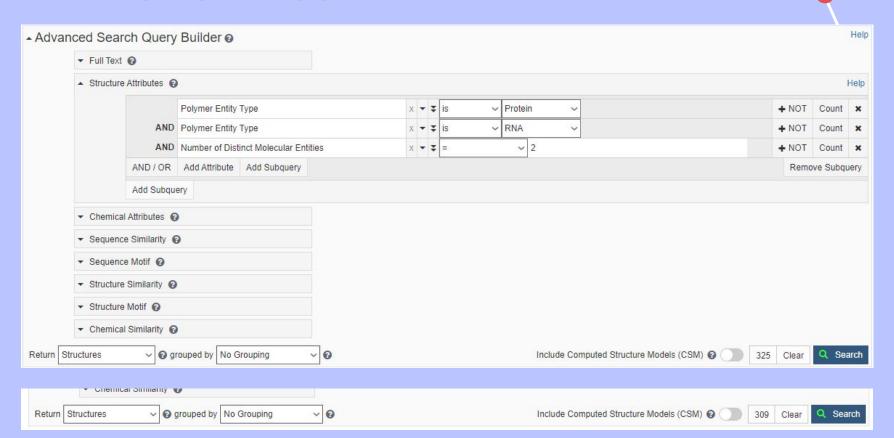




ATUALIZANDO DADOS



MÉTODO DE COLETA



BANCO DE DADOS ESTRUTURAL



Após filtrar nossas estruturas de interesse, com apenas uma molécula de RNA e uma de Proteína, ficamos com um total de 204 estruturas

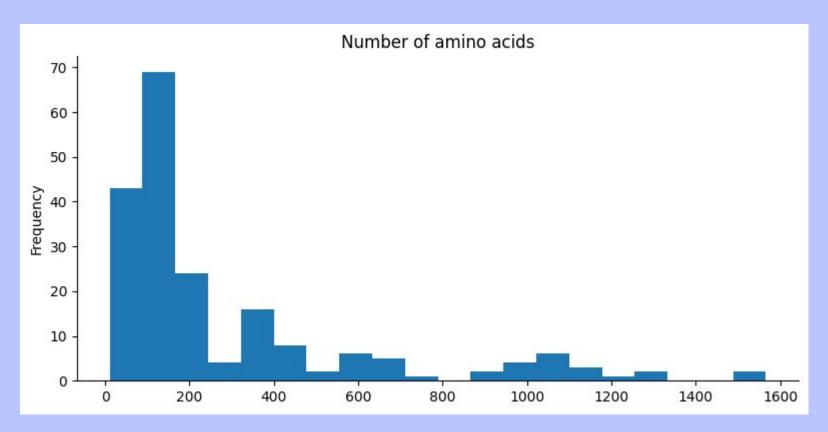


| | Structure | Number of amino acids |
|------|--------------|-----------------------|
| 0 | 1a4t | 19 |
| 1 | 1aud | 101 |
| 2 | 1biv | 17 |
| 3 | 1d6k | 94 |
| 4 | 1ekz | 76 |
| | | |
| 199 | 8pdl | 351 |
| 200 | 8pdm | 351 |
| 201 | 8pzp | 470 |
| 202 | 8qgt | 1289 |
| 203 | 8sxu | 726 |
| 04 r | ows × 2 colu | umns |



HISTOGRAMA AMINOÁCIDOS

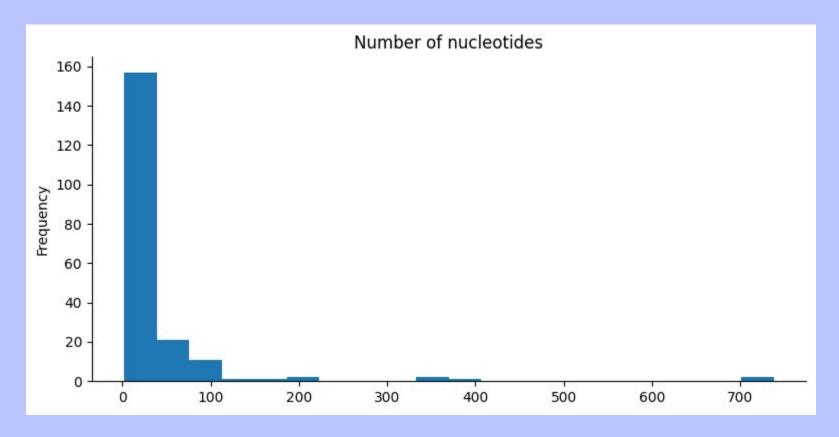






HISTOGRAMA NUCLEOTÍDEOS

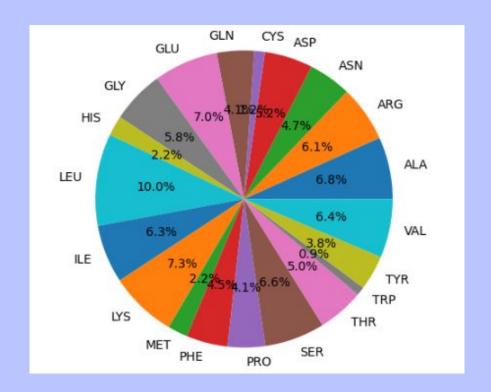




Frequência por Aminoácido

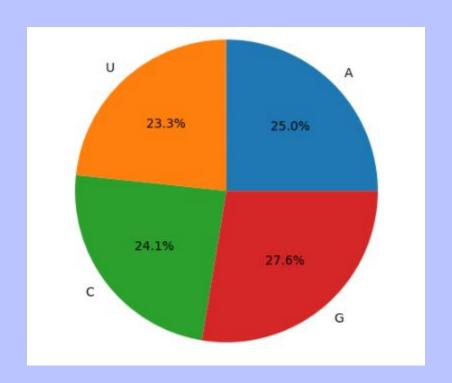






Frequência por Nucleotídeo







BANCO DE DADOS ESTRUTURAL



Ao final de todos os filtros, ficamos com um total de 175 estruturas no nosso banco atualizado



| | Structure | Number of amino acids | Number of nucleotides |
|-----|-----------|-----------------------|-----------------------|
| 0 | 1a4t | 19 | 15 |
| 1 | 1aud | 101 | 30 |
| 2 | 1biv | 17 | 28 |
| 3 | 1d6k | 94 | 37 |
| 4 | 1ekz | 76 | 30 |
| | *** | | *** |
| 170 | 8fti | 737 | 97 |
| 171 | 8pdl | 351 | 7 |
| 172 | 8pdm | 351 | 7 |
| 173 | 8pzp | 470 | 12 |
| 174 | 8sxu | 726 | 10 |





MODELANDO ESTRUTURAS







ALPHAFOLD 3



Inicialmente utilizariamos o RosettaFoldNA para realização deste estudo, porém no último dia 8 de Maio, foi lançado o **AlphaFold 3** com a possibilidade de modelar estruturas de DNA e RNA.

ΔΙ

AlphaFold 3 predicts the structure and interactions of all of life's molecules

Introducing AlphaFold 3, a new Al model developed by Google DeepMind and Isomorphic Labs. By accurately predicting the structure of proteins, DNA, RNA, ligands and more, and how they interact, we hope it will transform our understanding of the biological world and drug discovery.

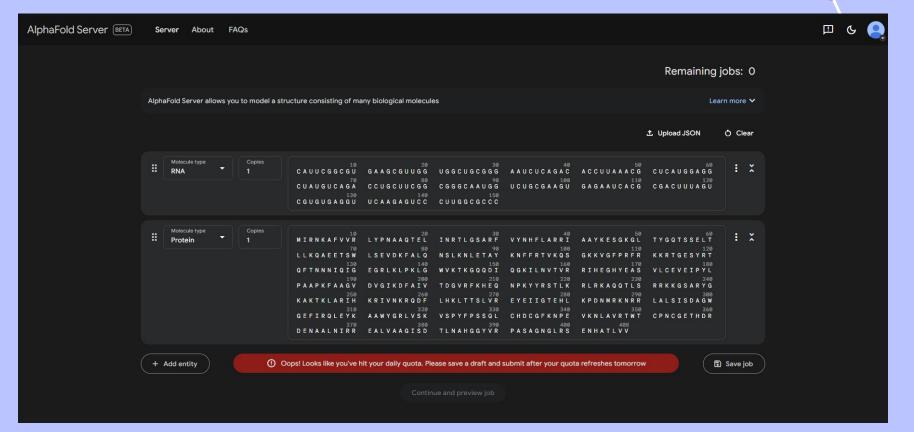
May 08, 2024 6 min read





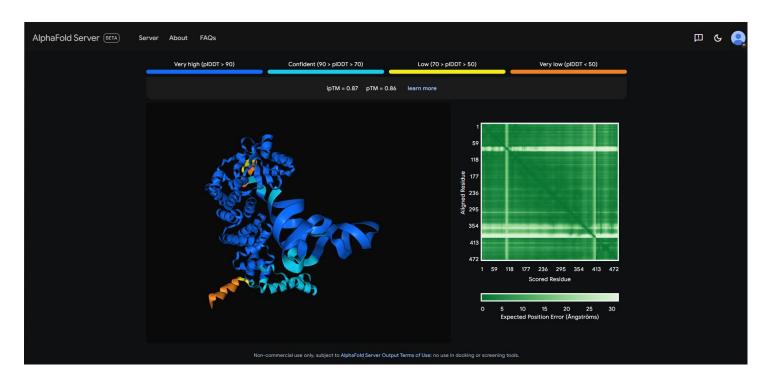


APHAFOLD SERVER



MODELAGEM DE ESTRUTURAS

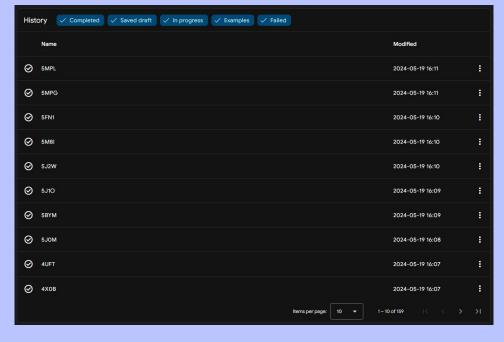




TOTAL DE ESTRUTURAS MODELADAS



Com o AlphaFold Server, foi possível modelar **159** estruturas, visto que algumas tinham apenas **3** nucleotídeos, o que impossibilitou a modelagem com o AlphaFold 3





TRATAMENTO DOS DADOS



- Remoção de cabeçalho
- Remoção de resíduos gerados durante o processo de sequenciamento

| 3 | MOTA | 3 | C4" | G | A | 4 | 11.190 | 6.700 | 5.875 | 1.00 | 8.88 | C |
|-----|------|----|-------|---|---|---|--------|-------|--------|------|------|---|
| 4 | ATOM | 4 | 04" | G | A | 4 | 12.365 | 5.959 | 5,435 | 1.00 | 0.00 | 0 |
| 5 | MOTA | 5 | C3* | G | A | 4 | 10.264 | 5.544 | 4.657 | 1.00 | 0.00 | C |
| 6 | ATOM | 6 | 03" | G | A | 4 | 9.300 | 7.705 | 4.620 | 1.00 | 0.00 | 0 |
| 7 | ATOM | 7 | C2" | G | A | 4 | 11.235 | 6.678 | 3.482 | 1.00 | 0.80 | C |
| 8 | ATOM | 8 | 02" | G | A | 4 | 11.451 | 7.949 | 2.868 | 1.00 | 8.88 | 0 |
| 9 | ATOM | 9 | C1' | G | A | 4 | 12.534 | 6.100 | 4.016 | 1.00 | 0.00 | C |
| 10 | MOTA | 10 | N9 | G | Α | 4 | 12.901 | 4.816 | 3.367 | 1.00 | 0.00 | N |
| 11 | ATOM | 11 | C8 | G | A | 4 | 12.912 | 3.591 | 3.921 | 1.00 | 0.00 | C |
| 12. | ATOM | 12 | N7 | G | А | 4 | 13.279 | 2.521 | 3.121 | 1.00 | 0.00 | N |
| 13 | MOTA | 13 | C5 | G | A | 4 | 13.534 | 3,248 | 1.930 | 1.00 | 0.00 | C |
| 14 | MOTA | 14 | C6 | G | A | 4 | 13.958 | 2.683 | 0.720 | 1.00 | 0.00 | C |
| 15 | MOTA | 15 | 06 | G | Α | 4 | 14.185 | 1.483 | 0.537 | 1.00 | 0.00 | 0 |
| 16 | MOTA | 16 | N1 | G | A | 4 | 14.106 | 3.675 | -0.294 | 1.00 | 0.00 | N |
| 17 | ATOM | 17 | C2 | G | А | 4 | 13.870 | 5.055 | -0.145 | 1.00 | 0.00 | C |
| 18 | ATOM | 18 | N2 | G | A | 4 | 14.093 | 5.754 | -1.293 | 1.00 | 0.00 | N |
| 19 | ATOM | 19 | N3 | G | A | 4 | 13.460 | 5.557 | 1.052 | 1.00 | 0.00 | N |
| 20 | ATOM | 20 | C4 | G | A | 4 | 13.311 | 4,522 | 2.034 | 1.00 | 0.00 | C |
| 21 | ATOM | 21 | H5 " | G | A | 4 | 10.263 | 5.022 | 6.937 | 1.00 | 0.00 | H |
| 22. | MOTA | 22 | H5' " | G | A | 4 | 11.408 | 6.001 | 7.924 | 1.00 | 0.00 | H |
| 23 | MOTA | 23 | H4 ° | G | A | 4 | 11.546 | 7.732 | 6.079 | 1.00 | 0.00 | H |
| 24 | MOTA | 24 | H3 * | G | A | 4 | 9.785 | 5.642 | 4.630 | 1.00 | 0.00 | Н |
| 25 | ATOM | 25 | H2* | G | A | 4 | 10.853 | 5.939 | 2.744 | 1.00 | 0.00 | H |
| 26 | ATOM | 26 | H02" | G | A | 4 | 11.848 | 7.896 | 1,998 | 1.00 | 0.00 | H |



Próximos Passos

- Finalizar modelagem das estruturas faltantes
- Passar estruturas geradas pelo AlphaFold 3 pelas mesmas análises feitas com os dados do PDB
- Comparar estruturas nativas coletadas do PDB com aquelas gerados pelo AphaFold



REFERÊNCIAS BIBLIOGRÁFICAS

Abramson, J., Adler, J., Dunger, J. et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3. Nature (2024). https://doi.org/10.1038/s41586-024-07487-w

BERMAN, Helen M; BATTISTUZ, Tammy; BHAT, Talapady N; et al. The Protein Data Bank. Acta Crystallographica Section D-biological Crystallography, v. 58, n. 6, p. 899–907, 2002. Disponível em: https://scripts.iucr.org/cgi-bin/paper?an0594>. Acesso em: 11 set. 2023.

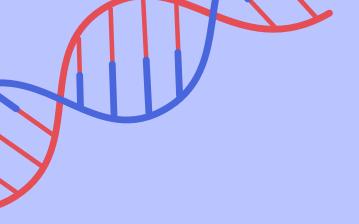
DE ARAÚJO, Nilberto Dias et al. A era da bioinformática: seu potencial e suas implicações para as ciências da saúde. Estudos de biologia, v. 30, n. 70/72, 2008. Disponível em: https://biblat.unam.mx/hevila/Estudosdebiologia/2008/vol30/no70-72/16.pdf. Acesso em: 12 set. 2023.

HERBERT, Katherine G; JUNILDA SPIROLLARI; WANG, Jianli; et al. Bioinformatic Databases. Wiley Encyclopedia of Computer Science and Engineering, 2007. Disponível em: https://onlinelibrary.wiley.com/doi/abs/10.1002/9780470050118.ecse561. Acesso em: 13 set. 2023.

MARIANO, D. C. B.; BARROSO, J. R. P. M.; CORREIA, T. S.; de MELO-MINARDI, R. C. . Introdução à Programação para Bioinformática com Biopython. 3. ed. North Charleston, SC (EUA): CreateSpace Independent Publishing Platform, 2015. v. 1. 230p .

PIRES, Douglas E V; RAQUEL; CARLOS; et al. aCSM: noise-free graph-based signatures to large-scale receptor-based ligand prediction. Bioinformatics, v. 29, n. 7, p. 855–861, 2013. Disponível em: https://academic.oup.com/bioinformatics/article/29/7/855/253252. Acesso em: 11 set. 2023.

WU, Cathy H; YEH, Lai-Su L; HUANG, Hongzhan; et al. The Protein Information Resource. Nucleic Acids Research, v. 31, n. 1, p. 345–347, 2003. Disponível em: https://academic.oup.com/nar/article/31/1/345/2401247>. Acesso em: 13 set. 2023.



Obrigado!

